

Between Potential and Ideal - split chapter

בינה מלאכותית ובעיות פתוחות

תשובה, מקור, אחריות והמרחק שנגנב.

השאלה הפנימית של AI

מה קורה כאשר מערכת יכולה להפיק תשובה, צורה, קול, תמונה, קוד, החלטה, המלצה, סיכום, אבחנה, דירוג או פעולה — בלי לעבור את הדרך האנושית שבה אמת, אחריות, מקור, הבנה ומשמעות היו אמורים להיווצר?

AI אינו רק כלי חדש. הוא מאיץ בעיות ישנות: תוצאה בלי דרך, צורה בלי מקור, תשובה בלי הבנה, פעולה בלי אחריות, מדד בלי שיפוט, סבירות בלי אמת, קול בלי אדם, החלטה בלי מצפון וידע בלי מרחק. משפחות הבעיות הפתוחות

1. אמת ועדות: OWASP hallucination, deepfakes, provenance, misinformation, evaluation gap. prompt injection, חשיפת מידע רגיש, שרשרת אספקה וסוכנות עודפת כסיכונים מרכזיים ליישומי LLM; לכן הבעיה אינה רק "מודל טועה", אלא גבול פגיע בין טקסט, הוראה ופעולה. מקור: OWASP Top 10 for LLM Applications.

2. דרך והבנה: deskilling, חינוך, קוד, כתיבה, overreliance וקיצור דרך. AI יכול לתת תוצר לפני שהמשתמש עבר את המרחק שבו יכולת הייתה אמורה להיווצר.

3. מקור חי: זכויות יוצרים, הסכמה, קול, סגנון, WIPO likeness, training data, provenance. עוסק בשאלות AI וקניין רוחני; בתאוריה זו הבעיה עמוקה יותר: מקור חי קודם למידע המופק ממנו. מקור: WIPO AI and IP.

4. פעולה ואחריות: agents, tool use, authorization, auditability, liability. כשהמודל עובר מתשובה לפעולה, הפוטנציאל הופך לאירוע.

5. כוח ומוסד: compute, data, cloud, פלטפורמות, רגולציה, surveillance, עבודה, צבא. Stanford AI Index 2025 מתאר התרחבות של AI לחיי יום-יום, בריאות, תחבורה ועסקים; זו כבר תשתית, לא צעצוע. מקור: Stanford AI Index 2025.

6. ערכים ואידיאל: NIST AI alignment, reward hacking, proxy goals, value pluralism, oversight. RMF ופרופיל GenAI מתייחסים לניהול סיכונים ואמון במערכות AI; מבחינת התאוריה, זו שאלת האידיאל כשהוא מתורגם למערכת פעולה. מקור: NIST AI RMF. מפת אמת-מקור-בדיקה

האם יש מקור? האם המקור תומך במסקנה? האם המודל יודע מה אינו יודע? האם יש דרך בדיקה חיצונית? האם המשתמש יכול לראות את המרחק בין הטענה לבין המקור?

הבעיה של hallucination אינה רק שגיאה. היא הפרדה בין רהיטות לבין אחריות לאמת. תשובה יכולה להישמע כעדות גם כאשר אינה נושאת מקור. מפת הרשאה-פעולה-ניקוז

מה הכלי רשאי לעשות? מה בלתי הפיך? איפה נדרש אישור אנושי? האם יש תיעוד? האם יש rollback? האם יש גבול נזק? האם יש מערכת שמזהה חריגה?

סוכן AI עם הרשאות אינו "צ'אט חכם יותר". הוא מערכת פעולה. לכן כל הרשאה חייבת ניקוז: audit trail, sandbox, אישור אנושי, הגבלת נזק, יכולת עצירה ויכולת תיקון. אופק מקור ומבחן טיורינג ההפוך

לעיתים הפלט נראה, אבל הדרך שהולידה אותו אינה נגישה: דאטה אימון, משקלים, retrieval, fine-tuning, feedback, prompts והקשר. זהו אופק מקור.

מבחן טיורינג ההפוך אינו שואל האם המכונה נראית כאדם. הוא שואל האם האדם, המקור, הדרך והעדות עדיין ניתנים לזיהוי אחרי שהתוצר עבר דרך מכונה.